#### From OCR to Multimodal LLMs

Building a Textbook Corpus with ALICE

Steven Denney Leiden University

ALICE-SHARK User Meeting 2025 June 3, 2025


# Why This Project?

- Textbooks are key to understanding civic education, national identity, and state discourse, especially over long periods of time.
- OCR quality on historical text in non-Latin scripts (e.g., Korean) is often poor, especially when using English-centric tools.
- By working with Korean text and a Korean-trained LLM (EXAONE), this project demonstrates the viability of non-English, script-specific LLM pipelines.
- ALICE enables local, high-performance language model inference ideal for multilingual document workflows.

## Corpus Construction Goals

- Build a clean, searchable corpus from scanned Korean textbooks.
- Compare and evaluate two workflows:
  - 1. Pipeline A: Traditional OCR + LLM cleaning
  - 2. Pipeline B: Vision-language model + LLM post-editing
- Optimize for ALICE: GPU-accelerated, fully local, efficient.

## What We're Working With Here



이 리 말
수의 나와 역사는 수의 민국이 살아는 경우원로서, 오늘의 수
의 생활로 아이지도 있다. 그리르도, 수의 연속 등부처는 것은
가는 수의 민국 문제를 가는 그는 소리 가를 보고 있는데 무슨 연한 아니라, 수의가 하나 및 것을 연할다. 미리의 나라를 바른 방법 수 있는 길이 될 것이다. 구리는 이에 작면 되고, 학학교에서 수의 역사를 통부하였다. 기업을 어떤 역인 되고, 학학교에서 수의 역사를 통부하였다.

구위는 이에 작면 학교, 축락교에서 우리 역사를 공부하였다. 이제는 우리 소스로가 우리 문화를 통표하고 말전시의 준 원원을 찾아보고, 우리 문화의 시대적 성격하 발전 과정을 것이 이뤄하 나가야 할 것이다. 우리 방송의 도착점이 있어요.

우리 전략이 주세적인 언어와 문자를 가지고 수պ의 문화를 발 됩시키는 선생님이 가꾸는 말로, 그리고 기억의 경신이다. 속구 당석가가 경계하는 동안, 우리는 수백년 이렇다 단속이나 속가의 목한 연수가 경계하는 동안, 우리는 수백년 이렇다 간략이, 무기의 부는 모두로 교육하여 상기들이 조르시키 너는 문화를 하는 일차에 가는 있었으나, 그걸 때하는 목에 대한 문화를 하는 일차에 가도 있었으나, 그걸 때하는 우리 전략은 받아 위기에 지원 경 에 이끌다. 그리어, 옷인 여름은 속에서도 생겨 울세 부 전 인질로, 그리어, 옷인 여름은 속에서도 생겨들로 수 위의 전인들을 보다 구었고, 가정할 문화로 안석하여 활각되.

이제 우리는, 우리 민족의 네무요부터의 발전을 우구해 온 금을 제대로 알어, 서제사의 초등 속에서 우리 민족이 발전하고 문화 장조를 이욱한 모두도 깊이 살려야 할 것이다.

Cover page

Introduction page


# Language, Modularity, and Scale

- This pipeline is prototyped on Korean text ideal for testing non-Latin scripts.
- EXAONE is used because it is trained on Korean but other LLMs could be substituted.
- Pipeline is modular: Vision model, LLM, and post-processing components are interchangeable.
- Goal: develop a scalable, multilingual corpus-building framework for diverse scripts.


# Pipeline Typical (Legacy Approach)

- The traditional pipeline relies entirely on OCR:
  - 1.  $PDF \rightarrow Image conversion$
  - 2. Image  $\rightarrow$  OCR engine (e.g., Tesseract or EasyOCR)
  - 3. Output stored as raw or segmented plain text
  - 4. Optionally post-processed and structured manually or semi-manually into JSON or XML
- Works reasonably well for clean Latin-script sources, but performs poorly on layout-rich or non-Latin texts.

### Pipeline A: OCR-Based Workflow



# Pipeline B: Prototype Workflow (Vision Language Model)



#### Model Infrastructure: Ideal and Tested

Ideal setup for scalable, high-quality inference:

- EXAONE-Deep 70B (Q5\_K\_M) Korean-specific LLM used for post-processing and normalization. High performance; fits on ALICE GPU nodes via quantization.
- LLaVA-1.5 + Mistral 7B Open-source multimodal model for direct image-to-text interpretation. Supports OCR-free pipeline design, and runs efficiently with quantized weights on ALICE GPUs.

#### Tested alternatives via local prototyping:

- EXAONE 7B Used for early-stage post-cleaning; faster but with slightly reduced performance.
- MiniGPT-4, LLaVA-1.5 Lightweight VLMs tested for proof-of-concept inference. Run on consumer GPU, but slow(er) and less reliable than ideal models.

# Comparing the Pipelines

Feature	Pipeline A (OCR)	Pipeline B (VLM)
Accuracy	Moderate, layout lost	Promising, preserves layout
Speed	Stable but multi-step	Faster per step, but newer
Robustness	OCR is (semi-)reliable	VLMs still evolving
Deployment	Simple batch processing	Needs better fallback/error
		handling

## Pipeline B: Built for ALICE?

- Entire pipeline executes on ALICE no cloud dependencies, full data control.
- Uses quantized models (e.g., EXAONE 70B Q5\_K\_M) for efficient GPU inference on single nodes.
- Vision-Language inference and LLM post-processing both benefit from ALICE's parallel architecture.
- Enables testing, tuning, and benchmarking of large multilingual models in-house.
- Future: add automated fallback from VLM to OCR and batch-parallel scaling across textbook collections.

# Next Steps and Broader Considerations

- Fine-tune VLM interpretation on Korean textbook samples.
- Release annotated corpus + pipeline documentation for other researchers/socializing.
- Assess tradeoffs: Is multimodal extraction truly necessary? Does it justify the extra compute and complexity?

#### Thank You

```
Project materials and code (work in progress): https://github.com/scdenney/textbook-pipeline/tree/main
```

Contact: s.c.denney@hum.leidenuniv.nl